

NOMBRE: Benjamín Farías Valdés

N.ALUMNO: 22102671



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE CIENCIA DE LA COMPUTACIÓN

IIC3692 — Tópicos Avanzados en Inteligencia Artificial — 2' 2022

Lectura 18

Crítica

Inductive Representation Learning on Large Graphs

El paper introduce una arquitectura denominada *GraphSAGE*, que actúa sobre grafos y permite generar *embeddings* para los nodos, aprendiendo funciones de agregación sobre los vecindarios de los nodos en vez de aprender directamente la representación de cada nodo (que era la técnica utilizada principalmente hasta ese momento).

El aporte principal de este trabajo está en la construcción de un *framework* que utiliza aprendizaje inductivo en vez de transductivo. Este tipo de aprendizaje se enfoca en obtener reglas generales a partir de los datos de entrenamiento, a diferencia del transductivo, que sólo aprende a ajustarse a los datos que son fijos y específicos. Este cambio de estrategia está debidamente justificado, ya que existen muchas aplicaciones de grafos en donde se agrega nueva información constantemente (por ejemplo los sistemas recomendadores), por lo que claramente no es escalable el entrenar un modelo de *GNN* cada vez que cambia algo en el grafo.

Me hace mucho sentido la forma en que se modela el conocimiento en la propuesta, ya que se entrenan funciones que son capaces de extraer la información de los nodos vecinos y luego condensarla para actualizar el estado del nodo actual. Esto permite hacer un modelo general que, sin importar el grafo, sabe como traspasar esta información entre nodos de forma que sea posible encontrar representaciones con calidad respetable. Además, se prueba con los experimentos que esto es exitoso en la práctica, logrando superar a métodos como *DeepWalk* (*approach* basado en factorización matricial). Algo interesante a rescatar aquí es que se probaron/entrenaron varias funciones de agregación, y a pesar de que todas obtuvieron resultados similares, la mejor en términos de balance entre costo de entrenamiento y rendimiento fue una basada en *max pooling* sobre una capa densa. Esto último indica que quizás la mejor forma de modelar características de grupos de nodos en grafos sea mediante redes neuronales simples, gracias a su flexibilidad estructural, en vez de seguir técnicas diseñadas a mano o usar arquitecturas más complejas de forma innecesaria.

Una limitación clara de este enfoque es que sólo es posible considerar una vecindad reducida de cada nodo al entrenar, ya que de otra forma sería demasiado costoso. En el espectro de pruebas del artículo, el modelo parece comportarse bien con valores reducidos del parámetro que regula el tamaño de la vecindad. A pesar de esto, creo que en ciertas aplicaciones sería beneficioso tener alguna forma de medir mejor la relación (o falta de esta) entre nodos muy alejados entre sí, y en esta arquitectura eso no es posible al usar un tamaño de vecindad reducido. Esto último quizás sería útil, por ejemplo, para redes sociales, en donde el algoritmo debe recomendar amigos nuevos a un usuario, y esas personas podrían estar bien alejadas en la red pero ser

compatibles con el usuario.

En general me pareció una interesante propuesta, que se apoya en trabajos anteriores sobre redes de grafos pero cambiando el enfoque del aprendizaje, pasando de uno transductivo a uno inductivo. Este cambio me suena similar a los mismos temas trascendentales al curso: pasar de redes profundas enfocadas en algo específico a redes multi-tarea y que son capaces de razonar de forma general.